

Курсовой проект • первый рубежный контроль

Анализ данных строительных инспекций для приоритизации контроля

Тема проекта: «Автоматизация строительного контроля и управления качеством СМР». Автор: Медиханов Тимур. Аналитическая часть самостоятельного учебного проекта. Связь с дипломом не заявляется.

Дата подготовки: 9 октября 2026 года. Источник: Chicago Building Violations, Chicago Data Portal, набор 22u3-xeng.

Аннотация

Исследован полный доступный снимок из 2 032 070 записей нарушения и 26 полей. После объединения записей по номеру инспекции и отбора однозначных результатов получено 357 763 наблюдений для бинарной классификации. Проведены аудит качества по восьми пунктам, разведочный анализ с семью графиками и сравнение константной модели с логистической регрессией на временном тесте.

На 2025 году Average Precision логистической модели составляет 0.928; у константной точки отсчёта — 0.794. Предварительный критерий успеха достигнут. Результат относится к зарегистрированным в архиве инспекциям и требует проверки на локальных данных перед практическим использованием.

Состав сдаваемого результата

Постановка задачи; паспорт источника; восемь проверок качества; EDA с выводами; baseline; план дальнейшей работы и риски. Код, notebook, таблицы, графики и материалы размещены в репозитории. Разработка ERP-приложения и внедрение не входят в оценку этой работы.

1. Постановка задачи и критерий успеха

Пользователь результата — руководитель службы строительного контроля или координатор инспекций. Его решение — какие из уже запланированных проверок требуют более раннего внимания и дополнительной подготовки. Выход аналитики — вероятность FAILED и очередь приоритетов; решение о результатах самой проверки принимает инспектор.

Единица наблюдения — инспекция, определённая `inspection_number`. Цель — оценить $P(\text{FAILED} \mid \text{метаданные запланированной инспекции})$ среди наблюдений с однозначным FAILED или PASSED, представленных в журнале нарушений. Задача является бинарной классификацией с последующим ранжированием.

Предполагаемый момент прогноза — до осмотра. На входе: назначенная служба, категория проверки, календарная дата и известные координаты объекта. Их доступность в реальной системе пока не подтверждена. Текущий статус, список нарушений и результат устранения не используются.

Ошибка	Практическое последствие	Учебная цена
FN: FAILED предсказан как PASSED	Проблемная проверка получает низкий приоритет; задержка реакции и дополнительной подготовки.	5 условных единиц
FP: PASSED предсказан как FAILED	Лишнее внимание и расход ограниченного времени специалиста.	1 условная единица

Соотношение 5:1 — учебная гипотеза, а не измеренный денежный ущерб и не экспертная оценка. Оно применяется одинаково к обеим моделям. Без подтверждения стоимости и доступной мощности проверок оптимальный порог нельзя считать операционным решением.

Предварительный критерий: на отложенном годе AP выше константного baseline минимум на 0.05, recall FAILED не ниже 0.80, precision не ниже доли FAILED на этом тесте. Порог выбирается только на validation по минимуму $(5 \times \text{FN} + \text{FP}) / N$. AP оценивает ранжирование, recall — пропуск проблемных проверок, precision — расход внимания.

2. Источник, формат и ограничения доступа

Первичный источник — Department of Buildings города Чикаго. Владелец публикует исторические записи нарушений с 2006 года; несколько нарушений могут относиться к одной инспекции. Данные носят информационный характер и могут не отражать текущее состояние здания [1].

Параметр	Значение
Источник	data.cityofchicago.org · 22u3-xenr
Строк / полей	2 032 070 / 26
Период событий	2006-01-01 — 2026-10-08
Групп объектов / номеров инспекции	155 788 / 470 576
Различных кодов нарушения	1 574
CSV / Parquet ZSTD	931.3 / 94.7 МБ
Скачано (Asia/Almaty)	2026-10-09 16:48:53

Формат исходного экспорта — CSV UTF-8, 26 полей, даты представлены текстом. Для вычислений используется Parquet с явными типами и сжатием ZSTD. Открытый CSV экспорт скачан без учётной записи и без API-токена. Интернет требуется для получения нового снимка; после загрузки расчёты выполняются локально.

Ключевые поля: ID — запись нарушения; inspection_number — связь записей проверки; property_group — группа объектов; violation_date — дата события, используемая как приближение даты инспекции; inspection_status — наблюдаемый результат; department_bureau и inspection_category — организационный контекст; latitude/longitude — география.

Ограничения: источник изменяется; сервер может ограничить частоту запросов, а исторические статусы могут обновляться. Для повторения чисел сохранены SHA-256, время загрузки, метаданные и компактная таблица инспекций. Адреса и комментарии не нужны модели и не включены в компактную таблицу. Открытость источника не означает наличие подтверждённой свободной лицензии: новая лицензия на чужие данные не назначается.

3. Качество данных: пункты 1–4

Чек-лист преподавателя в предоставленном задании не раскрыт. Ниже применён стандартный аналитический чек-лист из восьми пунктов; это явное допущение проекта. Все количественные проверки выполнены на полном загруженном CSV, без подвыборки. Подробная машинная сводка — `reports/quality.json`.

Проверка	Измеренный результат	Решение
1. Структура и типы	26 полей; ошибки разбора дат: 0.	Явные типы, строгий CSV-парсер; потеря строк не допускается.
2. Полнота	Без ключей: 0; без координат: 2 020.	Пропуски считаются по всем полям; координаты импонируются внутри train.
3. Уникальность	Повторы ID: 0; полные повторы: 0.	ID нарушения и номер инспекции имеют разную гранулярность.
4. Допустимые значения	Некорректных дат: 0; координат вне рамки: 0.	Даты 2006–09.10.2026; грубая рамка 41.6–42.1 / –88–87.5.

Полнота и преобразование типов

Пропуском считается NULL или пустая строка после удаления крайних пробелов. Даты разбираются по явным форматам; неудачные преобразования отдельно проверяются против исходного текста. CSV читается в строгом режиме: `ignore_errors` не используется, поэтому ошибочные строки не могут исчезнуть незаметно.

Для признаков модели числовые пропуски заполняются медианой только обучающего периода, одновременно создаётся индикатор отсутствия значения. Категориальные пропуски обозначаются UNKNOWN. Пустые даты и ключи не имитируются искусственными значениями.

Повторы и географические границы

Совпадение `inspection_number` ожидаемо: это связь нескольких нарушений одной проверки, а не дубликат строки. При повторе ID сохраняется запись с самой поздней датой изменения. Координаты вне грубой рамки Чикаго заменяются пропуском, а сама инспекция сохраняется. Рамка — проверка здравого смысла, а не официальный полигон административной границы.

3. Качество данных: пункты 5–8

Проверка	Измеренный результат	Решение
5. Согласованность	Инспекций с разными датами: 41 744; обратных дат статуса: 0.	Проверка единства объекта, даты, службы, категории и статуса внутри инспекции.
6. Целевая метка	Бинарная выборка: 357 763; FAILED: 73.7%.	FAILED=1, PASSED=0; остальные статусы и конфликты исключены.
7. Репрезентативность	Один город; 155 788 групп объектов; 2026 неполный.	Архив нарушений не является полным реестром всех осмотров или СМР.
8. Утечка и время	Train ≤2023; validation 2024; test 2025; 8 исходных признаков.	Постфактум поля исключены; версии полей на момент осмотра недоступны.

Конфликт определяется как более одного непустого значения статуса, объекта, даты, службы или категории внутри `inspection_number`. Такие инспекции не используются для обучения: выбор первого или последнего значения без правила бизнес-процесса создавал бы произвольную разметку. Для EDA они сохранены с признаком `ambiguous`.

Все 41 744 исключения связаны с разными `violation_date` внутри одной инспекции; по статусу, объекту, службе и категории противоречий не обнаружено. Это неоднозначность приближения даты, а не доказанная ошибка источника. Консервативный отбор может сместить выборку: чувствительность к этому правилу нужно проверить после получения реальной даты осмотра.

FAILED и PASSED трактуются как наблюдаемые классы. CLOSED, HOLD и UNKNOWN не считаются успешной проверкой. Их число сохраняется в сводке, чтобы показать цену фильтрации. Условия отбора определены до обучения и одинаковы для всех периодов.

Репрезентативность ограничена механизмом попадания в журнал. Полные данные о зданиях без зарегистрированных нарушений и полный журнал всех инспекций отсутствуют. Поэтому нельзя оценить общий риск любого здания города или автоматически переносить частоты на стройплощадки Казахстана.

Утечка ограничена исключением текущих нарушений, комментариев, дат устранения, `inspection_waived` и результата проверки из признаков. Исторические `target`-агрегаты из прежнего `notebook` также исключены: последовательный порядок инспекций одного дня не подтверждает доступность их результатов. Остаточный риск — один современный снимок без версий полей на дату прогноза.

4. Подготовка данных и аналитический протокол

Этап	Что выполняется	Выход
raw	Загрузка полного CSV; хеш; метаданные; строгий разбор; типизированный Parquet.	CSV и manifest.json
processed	Нормализация строк; дедупликация ID; проверка дат; агрегация; поиск конфликтов.	inspections.parquet
model data	Отбор FAILED/PASSED без конфликтов; календарные признаки; сохранение полей для аудита.	model_data.parquet
analysis	7 EDA-графиков; временное разделение; fit train; порог validation; оценка test.	JSON, CSV, PNG, SVG

Из 2 032 070 строк сформировано 470 576 инспекций с корректным номером и датой. Для бинарной задачи осталось 357 763; исключено 112 813 из-за неоднозначного статуса или конфликтующих атрибутов. По каждой инспекции сохранено число исходных записей.


Дата инспекции приближена минимальной violation_date. Проверка единства даты внутри группы помогает обнаружить сомнительное соответствие, но не доказывает, что дата нарушения равна фактическому времени осмотра. Это ограничение должно быть снято полным реестром инспекций.

Поля n_violations и n_codes применяются в разведочном анализе, поскольку отражают структуру регистрации. Они отсутствуют в списке входов baseline: до текущего осмотра неизвестно, сколько нарушений будет найдено. Адрес, ID нарушения и инспектор тоже исключены из модели.

Код разделяет статистику по нарушениям и по инспекциям. Общие EDA-графики используют весь снимок; выбор порога и обучение никогда не используют test. EDA всего архива считается описанием данных, а не независимой проверкой гипотез.


5. EDA: полнота и временной охват

1. Полнота исходных полей



Максимальная доля пропусков — 80.6% в ssa. Даты статуса, комментарии и SSA не включены в модель; координаты заполняются медианой только по train с индикатором пропуска.

2. Объём наблюдений по годам




Максимум в архиве — 2006 год: 39,385 инспекций. 2026 год неполный и не используется как тест. Изменение объёма отражает и практику регистрации, поэтому не доказывает изменение качества зданий.

Аналитический вывод: большой размер архива не устраняет систематические пропуски и изменение процесса регистрации. Доля отсутствующих значений измеряется отдельно от аномальных диапазонов; неполный последний год не сравнивается с полными годами как равный по экспозиции.


5. EDA: метка и единица наблюдения

3. Результаты на уровне инспекций



В бинарной выборке FAILED составляет 73.7%. CLOSED, HOLD и UNKNOWN исключены: отсутствие FAILED не означает PASSED. Ассигнатура без метрик классов может скрывать пропуски проблемных проверок.


4. Почему строки нельзя считать инспекциями



Медиана — 3 записи, 95-й перцентиль — 13, максимум — 538. Доля FAILED по строкам перевзвешивает инспекции с большим числом нарушений. Число нарушений текущей проверки используется только в EDA.

Аналитический вывод: классифицировать следует инспекции, а не записи нарушения. Иначе сложные проверки получили бы больший вес, а записи одной проверки могли бы попасть одновременно в обучение и тест. Остальные статусы требуют отдельного исследования, а не автоматического превращения в отрицательный класс.

5. EDA: различия служб



Среди 10 крупнейших служб доля FAILED меняется от 31.9% до 93.3%. Служба — кандидат в признаки, но различие может отражать процедуры учёта. Интервалы описательные и не учитывают зависимость повторных инспекций одного объекта.

Интерпретация организационного контекста

Сравниваются десять служб с наибольшим количеством наблюдений в бинарной выборке. На графике показаны доли FAILED и 95% интервалы Уилсона. Большие группы дают более узкий описательный интервал, но повторные проверки одного объекта нарушают независимость наблюдений.


Различия служб могут объясняться содержанием процедур, составом объектов и тем, какие результаты попадают в журнал. Почти постоянный класс у отдельной службы — повод проверить семантику учёта; это не доказательство высокого или низкого качества работы службы.

Служба и категория включены в простую модель как доступные метаданные. Следующая проверка — модель без этих полей, чтобы измерить, какая часть качества является следствием маршрутизации инспекций. Перенос между службами и городами должен оцениваться отдельно.

Таблица `bureau_rates.csv` содержит число инспекций и долю FAILED для каждого отображённого подразделения. Она позволяет проверить, что вывод не основан на редкой группе из нескольких событий.


5. EDA: сезонность и география

6. Сезонность наблюдений и результата



В полных годах месячная доля FAILED составляет 71.6%–74.7%. Месяц кодируется циклически; это ассоциация, смешанная с составом служб и лет, а не причинный эффект сезона.

7. Пространственная концентрация инспекций



У 502 инспекций нет пригодных координат. Карта показывает интенсивность наблюдения в архиве, без нормировки на число зданий. География может помочь ранжированию, но не позволяет объявить район более опасным.

Аналитический вывод: календарные и пространственные поля могут описывать состав и интенсивность проверок. Для оценки районного риска нужны внешние знаменатели: количество зданий, их возраст и полный реестр осмотров. В проекте причинные и территориальные выводы не заявляются.

6. Baseline: признаки, модели и разделение

Выборка	Период	Инспекции	FAILED
train	2006-01-01 — 2023-12-31	328 294	73.0%
validation	2024-01-01 — 2024-12-31	10 594	76.9%
test	2025-01-01 — 2025-12-31	10 910	79.4%

Наблюдения 2026 года (7 965) не участвуют в оценке модели: год неполный. Разделение календарное, случайное перемешивание не применяется. Повторные объекты между train и test разрешены, поскольку предполагается работа на последующих проверках известного парка объектов.

Точка отсчёта — `DummyClassifier(strategy="prior")`. Она оценивает частоту FAILED по train и выдаёт одинаковую вероятность всем инспекциям; признаки не использует. Такая модель выявляет, насколько результат объясняется одной базовой частотой [2].


Вторая простая модель — логистическая регрессия с L2-регуляризацией ($C=1$, `lbfgs`, `max_iter=2000`). Два категориальных входа кодируются `OneHotEncoder(handle_unknown="ignore")`; шесть числовых входов заполняются медианой и стандартизуются. Преобразования обучаются в Pipeline только на train [3].

Входы: `department_bureau`, `inspection_category`, `year`, `month_sin`, `month_cos`, `dayofweek`, `latitude`, `longitude`. Циклическая пара `sin/cos` отражает близость декабря и января. Год описывает линейный тренд, поэтому экстраполяция на будущие годы — отдельный риск.

Для каждой модели перебирается порог от 0 до 1 с шагом 0.005 на 2024 году. Выбирается минимум учебной стоимости $5 \times FN + FP$; при равенстве берётся меньший порог. После этого модель и порог фиксируются и один раз оцениваются на 2025 году. Модель не переобучается на validation.

6. Baseline: результаты на 2025 годе

Модель	AP	ROC-AUC	Precision	Recall	Cost/N
Dummy prior	0.794	0.500	0.794	1.000	0.206
Logistic regression	0.928	0.810	0.814	0.998	0.190



Матрицы ошибок: строки — факт, столбцы — прогноз; положительный класс FAILED.

Порог логистической модели — 0.235. На тесте: FN=20, FP=1 968, TP=8 641, TN=281. Balanced accuracy=0.561, F1=0.897, Brier=0.119. Предварительный критерий успеха достигнут; это оценка внутри доступного архива.

При данном пороге приоритет получают 97.2% тестовых инспекций; доля ложных тревог среди PASSED — 87.5%. Учебная стоимость ниже Dummy на 8.0%. Высокий recall достигнут широкой очередью, поэтому практическая экономия внимания пока не доказана.

AP здесь — average_precision_score, сумма precision, взвешенная приростами recall, а не трапецидальная площадь PR-кривой [4]. ROC-AUC дополнительно характеризует ранжирование. Brier оценивает средний квадрат ошибки вероятности; меньше — лучше.

Доля объектов теста, встречавшихся в train: 66.9%. Такой тест соответствует следующим проверкам существующего парка, но не подтверждает перенос на новые объекты. Для него нужна дополнительная оценка по группам property_group.

7. План дальнейшей работы и риски

Этап после РК-1	Результат	Критерий завершения
Недели 8–9	Проверить семантику FAILED/PASSED, даты и доступность метаданных.	Словарь полей и подтверждённый момент прогноза.
Недели 10–11	Получить полный реестр инспекций и локальную выборку СМР.	Есть проверки без нарушений и однозначная разметка.
Недели 12–13	Rolling backtest; тест новых объектов; абляция служб; калибровка.	Стабильные метрики по периодам и подгруппам.
Недели 14–15	Проверить стоимость ошибок и лимит очереди; сравнить простое дерево.	Порог и precision@K согласованы с пользователем.
Риск	Значимость	Способ уменьшить
Смещение журнала нарушений	Высокая	Получить полный знаменатель инспекций; ограничить выводы до этого.
Чикаго ≠ локальный контроль СМР	Высокая	Независимая локальная оценка; не переносить готовый порог.
Обновление исторических статусов	Высокая	Версии событий и данные на момент принятия решения.
Дрейф служб и категорий	Средняя	Оценка по годам и службам; мониторинг частот.
Неизвестная цена ошибки	Средняя	Экспертное согласование, анализ 1:1 / 3:1 / 5:1 / 10:1.
Повторы объектов и редкие группы	Средняя	Групповые оценки; интервалы с учётом кластеров.

В рамках предмета дальнейшие шаги остаются аналитическими: уточнение данных, качества, постановки и простой модели. Разработка приложения, интеграция с ERP и внедрение — отдельные будущие работы проекта, не часть текущей сдачи.

8. Воспроизводимость, выводы и источники

Полный запуск: создать Python-окружение, установить requirements.txt, выполнить `python -m src.pipeline` и `python -m src.artifacts`. Интерактивный вариант — `notebooks/course_project.ipynb`. Для повторения baseline на зафиксированном снимке интернет не требуется: компактные `inspections.parquet` и `model_data.parquet` включены в репозиторий.

Исходный CSV и raw Parquet велики и исключены из Git; код скачивает их из первоисточника. Повторная загрузка живого архива может дать другие числа. SHA-256 фиксирует идентичность исходного файла, но не гарантирует его вечную доступность на сервере. Версии использованных библиотек сохранены в requirements.txt и reports/environment.json.

SHA-256 исходного CSV: `fd1c8de7cc2638a0464a190b65eb0461a829094f13742b080fccc50b4ff5fb42`

Старые замеры производительности от 26.09.2026 сохранены отдельно как историческое приложение: CSV 930.39 МБ, Parquet Snappy 149.29 МБ; чтение 15.25 и 1.581 секунды. Они относятся к иной машине и прежнему снимку, не выдаются за повторные замеры в этом отчёте. При выбранном масштабе Parquet и DuckDB подходят для локального аудита и агрегации, pandas — для таблицы инспекций.

Выводы

Аналитическая задача сформулирована условно на охват источника; качество проверено, а гранулярность исправлена до уровня инспекции. Семь EDA-графиков показывают пропуски, временной охват, баланс метки, множественность нарушений, службы, сезон и географию. Простая модель улучшает AP на 0.135 относительно частотной точки отсчёта. Практическая переносимость остаётся открытой до получения локальных данных и истории версий.

Источники (проверены 09.10.2026)

[1] Chicago Data Portal. Building Violations.

<https://data.cityofchicago.org/Buildings/Building-Violations/22u3-xenr> ; метаданные: `data/raw/source_metadata.json`.

[2] scikit-learn. DummyClassifier.

<https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyClassifier.html>

[3] scikit-learn. Common pitfalls: leakage and preprocessing.

https://scikit-learn.org/stable/common_pitfalls.html

[4] scikit-learn. average_precision_score.

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html