

КУРСОВОЙ ПРОЕКТ · РК-1 · DATA SCIENCE

Автоматизация строительного контроля и управления качеством СМР

Аналитическая часть самостоятельного учебного проекта

Постановка задачи · качество данных · 7 графиков EDA
Baseline · план дальнейшей работы · воспроизводимый код

КОМАНДА

Медиханов Тимур

ДАТАСЕТ

Chicago Building Violations
полный архив с 2006 года

ОБЪЁМ

2 032 070 записей
931 МБ в CSV

ДАТА АНАЛИЗА

09.10.2026

Кому и для какого решения нужен результат

ПОЛЬЗОВАТЕЛЬ	РЕШЕНИЕ	ВЫХОД
Координатор инспекций и руководитель строительного контроля.	Приоритет внимания к уже запланированной инспекции.	Вероятность FAILED среди записанных FAILED/PASSED.
FN: пропущенная проблемная проверка — 5 у.е. FP: лишнее внимание к успешной проверке — 1 у.е.		
Критерий: $AP \geq \text{Dummy} + 0.05$; $\text{recall} \geq 0.80$; $\text{precision} \geq \text{доли FAILED}$. Цена ошибки — учебная гипотеза. Решение проверяет специалист.		

Полный архив, но ограниченный охват

ПАРАМЕТР	СНИМОК 09.10.2026
Источник	Chicago Data Portal · 22u3-xenr
Строк / столбцов	2 032 070 / 26
Инспекции после агрегации	470 576
Бинарная выборка	357 763
Формат / доступ	CSV → Parquet ZSTD · открытый экспорт без токена

Журнал нарушений Чикаго: не все инспекции и не локальные данные CMP.
Результат нельзя переносить на другой город без проверки.

Восемь проверок качества данных

ПРОВЕРКА	РЕЗУЛЬТАТ	РЕШЕНИЕ
1. Структура и типы	26 полей; ошибки разбора дат: 0.	Явные типы, строгий CSV-парсер; потеря строк не допускается.
2. Полнота	Без ключей: 0; без координат: 2 020.	Пропуски считаются по всем полям; координаты импугируются внутри train.
3. Уникальность	Повторы ID: 0; полные повторы: 0.	ID нарушения и номер инспекции имеют разную гранулярность.
4. Допустимые значения	Некорректных дат: 0; координат вне рамки: 0.	Даты 2006–09.10.2026; грубая рамка 41.6–42.1 / –88––87.5.

Использован стандартный чек-лист: перечень преподавателя не предоставлен.

Восемь проверок качества данных

ПРОВЕРКА	РЕЗУЛЬТАТ	РЕШЕНИЕ
5. Согласованность	Инспекций с разными датами: 41 744; обратных дат статуса: 0.	Проверка единства объекта, даты, службы, категории и статуса внутри инспекции.
6. Целевая метка	Бинарная выборка: 357 763; FAILED: 73.7%.	FAILED=1, PASSED=0; остальные статусы и конфликты исключены.
7. Репрезентативность	Один город; 155 788 групп объектов; 2026 неполный.	Архив нарушений не является полным реестром всех осмотров или CMP.
8. Утечка и время	Train ≤2023; validation 2024; test 2025; 8 исходных признаков.	Постфактум поля исключены; версии полей на момент осмотра недоступны.

Использован стандартный чек-лист: перечень преподавателя не предоставлен.

Одна строка модели — одна инспекция

RAW

2 032 070

Записи нарушений
Строгий CSV-парсер
Хеш и метаданные

PROCESSED

470 576

Группировка inspection_number
Проверка конфликтов
Число нарушений для EDA

MODEL DATA


357 763

Только FAILED / PASSED
Конфликты исключены
8 входных признаков

Текущие нарушения, статус и результаты устранения исключены из входов модели.

Полнота исходных полей

1. Полнота исходных полей




ВЫВОД

Максимальная доля пропусков — 80.6% в ssa. Даты статуса, комментарии и SSA не включены в модель; координаты заполняются медианой только по train с индикатором пропуска.

Объём наблюдений по годам

2. Объём наблюдений по годам




ВЫВОД

Максимум в архиве — 2006 год: 39,385 инспекций. 2026 год неполный и не используется как тест. Изменение объёма отражает и практику регистрации, поэтому не доказывает изменение качества зданий.

Результаты на уровне инспекций

3. Результаты на уровне инспекций




ВЫВОД

В бинарной выборке FAILED составляет 73.7%. CLOSED, HOLD и UNKNOWN исключены: отсутствие FAILED не означает PASSED. Accuracy без метрик классов может скрывать пропуски проблемных проверок.

Почему строки нельзя считать инспекциями

4. Почему строки нельзя считать инспекциями




ВЫВОД

Медиана — 3 записи, 95-й перцентиль — 13, максимум — 538. Доля FAILED по строкам перевзвешивает инспекции с большим числом нарушений. Число нарушений текущей проверки используется только в EDA.

Результат зависит от службы

5. Результат зависит от службы





ВЫВОД

Среди 10 крупнейших служб доля FAILED меняется от 31.9% до 93.3%. Служба — кандидат в признаки, но различие может отражать процедуры учёта. Интервалы описательные и не учитывают зависимость повторных инспекций одного объекта.

Сезонность наблюдений и результата

6. Сезонность наблюдений и результата




ВЫВОД

В полных годах месячная доля FAILED составляет 71.6%–74.7%. Месяц кодируется циклически; это ассоциация, смешанная с составом служб и лет, а не причинный эффект сезона.

Пространственная концентрация инспекций

7. Пространственная концентрация инспекций



ВЫВОД

У 502 инспекций нет пригодных координат. Карта показывает интенсивность наблюдения в архиве, без нормировки на число зданий. География может помочь ранжированию, но не позволяет объявить район более опасным.



Временная оценка без текущих нарушений

ВЫБОРКА	ПЕРИОД	ИНСПЕКЦИИ	FAILED
train	2006–2023	328 294	73.0%
validation	2024–2024	10 594	76.9%
test	2025–2025	10 910	79.4%

Dummy prior → частота FAILED по train
Logistic regression → служба, категория, календарь и координаты
Порог: минимум $5 \times FN + FP$ на 2024; 2025 используется только для оценки.

Простая модель против частотной точки отсчёта

МОДЕЛЬ	AP	ROC-AUC	PRECISION	RECALL	COST/N
Dummy prior	0.794	0.500	0.794	1.000	0.206
Logistic regression	0.928	0.810	0.814	0.998	0.190



Порог: 0.235
FN: 20 · FP: 1 968
Критерий: достигнут
В приоритете 97.2% проверок.
Экономия внимания ещё не доказана.

Что проверить после первого рубежного контроля

ЭТАП	РАБОТА	ОСНОВНОЙ РИСК
8–9 недели	Уточнить статусы, даты и доступность полей	Утечка через изменённые поля
10–11 недели	Получить полный журнал и локальные данные	Смещение архива нарушений
12–13 недели	Backtest, новые объекты, модель без служб	Дрейф и переносимость
14–15 недели	Согласовать стоимость и лимит очереди	Учебная цена ≠ реальный ущерб

Текущая сдача — аналитика. Разработка и внедрение ERP остаются вне её объёма.

Все шесть пунктов задания покрыты

- 01 Постановка: пользователь, решение, критерий, ошибки
- 02 Источник: полный снимок, формат, доступ и ограничения
- 03 Качество: восемь проверок с измеренными результатами
- 04 EDA: семь графиков и выводы по каждому
- 05 Baseline: Dummy prior и логистическая регрессия
- 06 План: этапы, риски и способы их уменьшить


Ограничение: качество модели подтверждено только внутри доступного архива.

ВОСПРОИЗВОДИМОСТЬ

Отчёт · notebook · код
Зафиксированный снимок
Метрики и графики
GitHub-репозиторий


CSV против Parquet: размер на диске

CSV · ТЕКСТ, БЕЗ ТИПОВ И СЖАТИЯ



930,4 МБ

PARQUET · КОЛОНКИ, ТИПЫ, SNAPPY



149,3 МБ

×6,2

меньше места на диске


- типы дат и чисел хранятся в самом файле
- запрос читает только нужные столбцы
- сжатие Snappy без потерь

Если запросу нужны 2 столбца из 26, Parquet прочитает только их, а CSV придётся разобрать целиком, строка за строкой.

Иная машина и прежний снимок; показатели не измерены повторно.


Время чтения датасета в память

PD.READ_CSV



15,25 с

PD.READ_PARQUET



1,58 с

×9,6

быстрее чтение из Parquet

■

 медиана: CSV — 3 прогона, Parquet — 5

■

 DataFrame в памяти: 1,18 ГБ

■

 читались все столбцы

Все столбцы поместились: оценка 1,1 ГБ при 7,2 ГБ свободной памяти. Для предобработки pandas подходит.

Иная машина и прежний снимок; показатели не измерены повторно.

Агрегация прямо по Parquet-файлу

11,6 мс

группировка и подсчёт 2 030 101 строк по inspection_status · медиана 15 прогонов

```
SELECT inspection_status, count(*) AS n
FROM 'raw/building_violations.parquet'
GROUP BY 1 ORDER BY n DESC
```

DuckDB читает нужный столбец из Parquet и использует собственную память для выполнения запроса.

Иная машина и прежний снимок; показатели не измерены повторно.

СРАВНЕНИЕ

Тот же запрос в DuckDB по CSV

0,98 с

pandas groupby по DataFrame, уже
загруженному в память

46,6 мс

Доля FAILED по годам и службам:
pandas, чтение + groupby

0,32 с

То же в DuckDB: один SQL по
файлу

0,041 с

Итоговая ведомость замеров для отчёта

ПАРАМЕТР ЗАМЕРА	ФОРМАТ / ИНСТРУМЕНТ	ЗНАЧЕНИЕ
Размер исходного файла	CSV, текст	930,39 МБ
Размер сжатого файла	Parquet, Snappy	149,29 МБ
Время чтения в память	pandas · CSV	15,250 с
Время чтения из файла	pandas · Parquet	1,581 с
Агрегация по целевому столбцу	DuckDB SQL	0,0116 с
Память машины	RAM всего / свободно	8,4 / 7,6 ГБ

Медианы: чтение CSV — 3 прогона, Parquet — 5, DuckDB — 15. pandas читал все столбцы.

Иная машина и прежний снимок; показатели не измерены повторно.