

Автоматизация строительного контроля и управления качеством СМР

Приложение для корпоративной ERP-платформы

Аналитическая часть: качество данных, EDA и baseline
pandas · Parquet · DuckDB · scikit-learn

КОМАНДА

Медиханов Тимур

ДАТАСЕТ

Chicago Building Violations
полный архив с 2006 года

ОБЪЁМ

2 032 070 записей
931 МБ в CSV

ДАТА АНАЛИЗА

09.10.2026

0.9 ГБ

Риск инспекции: пользователь и решение

КОНТЕКСТ СТРОЙКОНТРОЛЯ

Координатор инспекций распределяет внимание между уже запланированными проверками. Модель оценивает вероятность FAILED до осмотра; инспектор подтверждает фактический результат.
Единица анализа — одна инспекция объекта.

ЦЕНА ОШИБКИ • УЧЕБНАЯ ГИПОТЕЗА 5:1

FN 5 у.е. — пропущенная проблемная проверка; задержка внимания к нарушениям.

FP 1 у.е. — лишнее внимание к успешной проверке; расход времени специалиста.

Стоимость не измерена в деньгах; доступность входных полей до осмотра требует подтверждения.

Пользователь Руководитель службы строительного контроля	КООРДИНАТОР
Решение Какие проверки требуют более раннего внимания	ПРИОРИТЕТ
Результат P(FAILED служба, категория, дата, координаты)	ВЕРОЯТНОСТЬ
Критерий AP ≥ Dummy + 0,05; recall ≥ 0,80; precision ≥ доли FAILED	TEST 2025

Контекст и структура данных

СПЕЦИФИКА СТРОЙКОНТРОЛЯ

Каждая инспекция объекта может содержать несколько записей нарушения. Аналитика объединяет этот поток на уровне проверки и оценивает риск её результата. ERP-приложение — дальнейшая часть проекта; здесь оценивается аналитика.



РЕЗУЛЬТАТ ИНСПЕКЦИИ • ДОЛЯ ЗАПИСЕЙ



ПАСПОРТ ДАТАСЕТА

Источник	Chicago Data Portal • 22u3-xenr
Записей (нарушений)	2 032 070
Столбцов	26
Период	01.01.2006 – 08.10.2026
Объектов (property group)	155 788
Типов нарушений	1 574
Инспекций	470 576
Целевая метка	inspection_status

От выборки к полному архиву


БЫЛО • ВЫБОРКА	
записей	111 602
размер CSV	32,62 МБ
столбцов	12
период	01.01.2021 – 24.01.2023

×29
по объёму

СТАЛО • ПОЛНЫЙ АРХИВ	
записей	2 032 070
размер CSV	931,34 МБ
столбцов	26
период	01.01.2006 – 08.10.2026

На 32 МБ разница между инструментами измерялась долями секунды и не могла быть аргументом. На полном архиве те же замеры показывают, где pandas упирается в память и зачем нужны Parquet и DuckDB.

Слои данных: raw → processes → features



src/pipeline.py – полный расчёт · notebooks/course_project.ipynb – анализ · src/presentation.py – сборка слайдов

Что сделано с данными в processes/

№	ШАГ	ЧТО СДЕЛАНО	ЭФФЕКТ
01	Дубликаты	Повторы ID → последняя версия по дате изменения	0
02	Категории	strip + upper; пустые строки → NULL	4 категориальных поля
03	Даты	Явный разбор; диапазон 2006 — 09.10.2026	0 ошибок разбора
04	Координаты	Пустые / вне рамки → NULL; инспекция сохраняется	2 020 строк
05	Агрегация	Группировка по inspection_number; проверка атрибутов	470 576 инспекций
06	Дата осмотра	Разные violation_date внутри номера → неоднозначность	41 744 исключений
07	Метка	FAILED / PASSED; остальные статусы исключены	357 763 для модели

41 744 — неоднозначность даты, а не доказанная ошибка источника. Без противоречий статуса, объекта и службы.

Какие поля доступны до текущей инспекции

ВХОДЫ ПРОСТОЙ МОДЕЛИ • 8 ПОЛЕЙ

department_bureau — назначенная служба

inspection_category — категория проверки

year — календарный год

month_sin / month_cos — циклический месяц

dayofweek — день недели

latitude / longitude — координаты объекта

В прежнем notebook было 15 признаков, включая историю результатов. История исключена из baseline: время доступности результатов и порядок проверок одного дня не подтверждены.

Категории

ONE-HOT

Неизвестная категория на тесте → handle_unknown=ignore

Числа

TRAIN ONLY

Медиана + индикатор пропуска + StandardScaler

Постфактум

ИСКЛЮЧЕНО

n_violations, n_codes, текущий статус, устранение, waived

История

СЛЕДУЮЩИЙ ЭТАП

Вернуть после проверки доступности событий во времени

Проверки качества: результат и решение

ПРОВЕРКА	ИЗМЕРЕННЫЙ РЕЗУЛЬТАТ	РЕШЕНИЕ
1. Структура и типы	26 полей; ошибки разбора дат: 0.	Явные типы, строгий CSV-парсер; потеря строк не допускается.
2. Полнота	Без ключей: 0; без координат: 2 020.	Пропуски считаются по всем полям; координаты импугируются внутри train.
3. Уникальность	Повторы ID: 0; полные повторы: 0.	ID нарушения и номер инспекции имеют разную гранулярность.
4. Допустимые значения	Некорректных дат: 0; координат вне рамки: 0.	Даты 2006–09.10.2026; грубая рамка 41.6–42.1 / –88––87.5.

Стандартный чек-лист: подробный перечень преподавателя не предоставлен.
Полный raw-аудит без подвыборки; ошибки чтения строк не игнорируются.


Проверки качества: результат и решение

ПРОВЕРКА	ИЗМЕРЕННЫЙ РЕЗУЛЬТАТ	РЕШЕНИЕ
5. Согласованность	Инспекций с разными датами: 41 744; обратных дат статуса: 0.	Проверка единства объекта, даты, службы, категории и статуса внутри инспекции.
6. Целевая метка	Бинарная выборка: 357 763; FAILED: 73.7%.	FAILED=1, PASSED=0; остальные статусы и конфликты исключены.
7. Репрезентативность	Один город; 155 788 групп объектов; 2026 неполный.	Архив нарушений не является полным реестром всех осмотров или CMP.
8. Утечка и время	Train ≤2023; validation 2024; test 2025; 8 исходных признаков.	Постфактум поля исключены; версии полей на момент осмотра недоступны.

Стандартный чек-лист: подробный перечень преподавателя не предоставлен.
Полный raw-аудит без подвыборки; ошибки чтения строк не игнорируются.

Пропуски в исходном архиве нарушений

ДОЛЯ NULL И ПУСТЫХ СТРОК • RAW • %



80,6 %


пропусков в поле SSA

- Не используется в baseline
- Координаты: медиана train + индикатор
- Даты статуса и комментарии исключены

Максимальная доля пропусков — 80.6% в ssa. Даты статуса, комментарии и SSA не включены в модель; координаты заполняются медианой только по train с индикатором пропуска.

Количество инспекций по годам

ОДНА ИНСПЕКЦИЯ = ОДИН НОМЕР • 2006–2026



39 385


максимум: 2006 год

- 2026 — неполный год
- Объём зависит от регистрации
- Test модели: полный 2025 год

Максимум в архиве — 2006 год: 39,385 инспекций. 2026 год неполный и не используется как тест. Изменение объёма отражает и практику регистрации, поэтому не доказывает изменение качества зданий.

Статусы на уровне инспекции

ДО ФИЛЬТРАЦИИ СТАТУСОВ И НЕОДНОЗНАЧНЫХ ДАТ



В бинарной выборке FAILED составляет 73.7%. CLOSED, HOLD и UNKNOWN исключены: отсутствие FAILED не означает PASSED. Ассигасу без метрик классов может скрывать пропуски проблемных проверок.


73,7 %

FAILED в бинарной выборке

- FAILED=1; PASSED=0
- CLOSED / HOLD / UNKNOWN исключены
- Ассигасу дополняется метриками классов

Сколько нарушений приходится на инспекцию

ГРУППЫ ПО ЧИСЛУ ЗАПИСЕЙ НАРУШЕНИЯ



Медиана — 3 записи, 95-й перцентиль — 13, максимум — 538. Доля FAILED по строкам перевзвешивает инспекции с большим числом нарушений. Число нарушений текущей проверки используется только в EDA.


3

записи: медиана

- 95-й перцентиль — 13
- Максимум — 538 записей
- Текущие нарушения используются только в EDA

Доля FAILED в десяти крупнейших службах

БИНАРНАЯ ВЫБОРКА • 95 % ИНТЕРВАЛЫ УИЛСОНА



31–93 %


разброс долей FAILED

- Процедуры учёта различаются
- Интервалы описательные
- Повторы объектов не учитываются


Среди 10 крупнейших служб доля FAILED меняется от 31.9% до 93.3%. Служба — кандидат в признаки, но различие может отражать процедуры учёта. Интервалы описательные и не учитывают зависимость повторных инспекций одного объекта.

Месяц: объём проверок и доля FAILED

ЧИСЛО ИНСПЕКЦИЙ • 2006–2025



ДОЛЯ FAILED • %



72–75 %


месячная доля FAILED

- Только полные годы
- Месяц кодируется sin / cos
- Сезон смешан с составом служб


В полных годах месячная доля FAILED составляет 71.6%–74.7%. Месяц кодируется циклически; это ассоциация, смешанная с составом служб и лет, а не причинный эффект сезона.

Где концентрируются зарегистрированные проверки

ПЛОТНОСТЬ ИНСПЕКЦИЙ • ЛОГАРИФМИЧЕСКАЯ ШКАЛА



Инспекций
в ячейке



Логарифмическая
шкала

502

инспекции без координат

- Карта показывает наблюдение
- Нет нормировки на число зданий
- Нельзя оценить опасность района

У 502 инспекций нет пригодных координат. Карта показывает интенсивность наблюдения в архиве, без нормировки на число зданий. География может помочь ранжированию, но не позволяет объявить район более опасным.

Временное разделение и обучение модели

ВЫБОРКА	ПЕРИОД	ИНСПЕКЦИИ	FAILED
train	2006-01-01 — 2023-12-31	328 294	73,0 %
validation	2024-01-01 — 2024-12-31	10 594	76,9 %
test	2025-01-01 — 2025-12-31	10 910	79,4 %

DUMMYCLASSIFIER • STRATEGY=PRIOR

Одна вероятность для всех инспекций — частота FAILED по train. Показывает, что можно получить без использования признаков.

LOGISTIC REGRESSION • L2 • C=1

Pipeline: OneHotEncoder + медиана + StandardScaler. lbfgs; max_iter=2000. Все преобразования обучаются только на train.

Порог: минимум 5×FN+FP на 2024. Test 2025 не участвует в настройке; 2026 неполный и исключён.

Две простые модели: проверка на 2025 годе

МЕТРИКА	DUMMY PRIOR	LOGISTIC REGRESSION
Average Precision	0,794	0,928
ROC-AUC	0,500	0,810
Precision FAILED	0,794	0,814
Recall FAILED	1,000	0,998
Balanced accuracy	0,500	0,561
F1 FAILED	0,885	0,897
Brier (меньше лучше)	0,168	0,119
Стоимость (5×FN+FP)/N	0,206	0,190

Test: 10 910 инспекций; FAILED 79,4 %. Порог: 0,235.
AP – average_precision_score, без трапецеидальной интерполяции PR-кривой.

Что стоит за высоким recall

DUMMY PRIOR

	PASSED	FAILED
PASSED	0	2 249
FAILED	0	8 661

строки — факт; столбцы — прогноз

LOGISTIC REGRESSION

	PASSED	FAILED
PASSED	281	1 968
FAILED	20	8 641

строки — факт; столбцы — прогноз

97,2 %

проверок получают приоритет

■ FN: 20; FP: 1 968

■ Ложные тревоги у PASSED: 87,5 %

■ Условная стоимость ниже Dummy на 8,0 %

Высокий recall достигнут широкой очередью. Учебный критерий выполнен, но экономия внимания ещё не доказана: нужен лимит очереди и precision@K.

План после первого рубежного контроля

ЭТАП	РАБОТА	РЕЗУЛЬТАТ / КРИТЕРИЙ
8–9 недели	Проверить FAILED/PASSED, реальную дату осмотра и доступность метаданных	Словарь полей; подтверждённый момент прогноза
10–11 недели	Получить полный журнал инспекций и локальную выборку CMP	Включены проверки без нарушений; понятна разметка
12–13 недели	Rolling backtest; тест новых объектов; абляция служб; калибровка	Устойчивые метрики по времени и подгруппам
14–15 недели	Согласовать цены ошибок и лимит очереди; сравнить простое дерево	Рабочий порог; precision@K; сравнение с baseline

Разработка, реализация ERP и внедрение – следующие работы проекта, вне текущей аналитической сдачи.

Ограничения результата и способы их уменьшить

РИСК	УРОВЕНЬ	КАК УМЕНЬШИТЬ
Архив нарушений не охватывает все инспекции	ВЫСОКИЙ	Получить полный журнал и знаменатель проверок
Чикаго отличается от локальных процессов CMP	ВЫСОКИЙ	Независимая проверка на локальных данных
Исторические статусы и поля могут меняться	ВЫСОКИЙ	Версии данных на момент принятия решения
Разные даты внутри inspection_number	СРЕДНИЙ	Реальная дата осмотра; анализ чувствительности отбора
Повторы объектов; дрейф служб и категорий	СРЕДНИЙ	Тест новых объектов; оценки по годам и службам
Цена ошибок 5:1 пока условная	СРЕДНИЙ	Согласование; сценарии 1:1 / 3:1 / 5:1 / 10:1

66,9 % объектов test уже встречались в train: текущая оценка относится к будущим проверкам известного парка.

Что сделано с данными в processes/


№	ШАГ	ЧТО СДЕЛАНО	ЭФФЕКТ
01	Дубликаты	повторы id: оставлена последняя версия записи	0
02	Категории	strip + upper, пустые строки → пропуски	5 столбцов
03	Даты	нет даты нарушения или она вне 2006 — сегодня: запись удалена	0
04	Дата статуса	раньше даты нарушения → пропуск	0
05	Координаты	вне границ Чикаго или пустые → пропуск	2 020
06	Агрегация	нарушения → инспекции (inspection_number)	2 030 085 → 470 057
07	Типы	category, downcast int, float32	98 → 53 МБ

Гранулярность processes: одна строка = одна инспекция объекта • целевая метка inspection_status

Исторические измерения автора: прежний снимок и машина; не повторные замеры.


CSV против Parquet: размер на диске

CSV • ТЕКСТ, БЕЗ ТИПОВ И СЖАТИЯ



930,4 МБ

PARQUET • КОЛОНКИ, ТИПЫ, SNAPPY



149,3 МБ

×6,2

меньше места на диске


- типы дат и чисел хранятся в самом файле
- запрос читает только нужные столбцы
- сжатие Snappy без потерь

Если запросу нужны 2 столбца из 26, Parquet прочитает только их, а CSV придётся разобрать целиком, строка за строкой.

Исторические измерения автора: прежний снимок и машина; не повторные замеры.


Время чтения датасета в память

PD.READ_CSV



15,25 с

PD.READ_PARQUET



1,58 с

×9,6

быстрее чтение из Parquet

- медиана: CSV — 3 прогона, Parquet — 5
- DataFrame в памяти: 1,18 ГБ
- читались все столбцы

Все столбцы поместились: оценка 1,1 ГБ при 7,2 ГБ свободной памяти. Для предобработки pandas подходит.

Исторические измерения автора: прежний снимок и машина; не повторные замеры.

Агрегация прямо по Parquet-файлу

11,6 мс

группировка и подсчёт 2 030 101 строк по inspection_status • медиана 15 прогонов

```
SELECT inspection_status, count(*) AS n
FROM 'raw/building_violations.parquet'
GROUP BY 1 ORDER BY n DESC
```

Прямое поколоночное сканирование: DuckDB читает нужный столбец и выполняет запрос в собственной памяти; загрузка в pandas не требуется.

Исторические измерения автора: прежний снимок и машина; не повторные замеры.

СРАВНЕНИЕ

Тот же запрос в DuckDB по CSV

0,98 с

pandas groupby по DataFrame, уже загруженному в память

46,6 мс

Доля FAILED по годам и службам: pandas, чтение + groupby

0,32 с

То же в DuckDB: один SQL по файлу

0,041 с

Итоговая ведомость замеров для отчёта

ПАРАМЕТР ЗАМЕРА	ФОРМАТ / ИНСТРУМЕНТ	ЗНАЧЕНИЕ
Размер исходного файла	CSV, текст	930,39 МБ
Размер сжатого файла	Parquet, Snappy	149,29 МБ
Время чтения в память	pandas • CSV	15,250 с
Время чтения из файла	pandas • Parquet	1,581 с
Агрегация по целевому столбцу	DuckDB SQL	0,0116 с
Память машины	RAM всего / свободно	8,4 / 7,6 ГБ

Медианы: чтение CSV — 3 прогона, Parquet — 5, DuckDB — 15. pandas читал все столбцы.

Исторические измерения автора: прежний снимок и машина; не повторные замеры.

Выбор инструментов, обоснованный цифрами

Датасет занимает 0,93 ГБ в CSV (2 030 101 запись). В Parquet тот же набор весит 149 МБ, в 6,2 раза меньше, и читается в pandas за 1,6 с против 15,2 с у CSV. По памяти: полная таблица занимает в pandas 1,2 ГБ при 7,2 ГБ свободной памяти, для предобработки pandas достаточно. Агрегация в DuckDB прямо по Parquet занимает 11,6 мс, сводный запрос по годам и службам выполняется в 7,8 раза быстрее, чем в pandas. Данные помещаются на одну машину с 8,4 ГБ памяти, обработка разовая, поэтому Spark избыточен: Parquet — для хранения, DuckDB — для агрегаций, pandas — для предобработки.

Исторические измерения автора: прежний снимок и машина; не повторные замеры.

Excel	НЕ ОТКРОЕТ
2 030 101 строк при пределе листа 1 048 576	
pandas	ПРЕДОБРАБОТКА
DataFrame 1,18 ГБ при 8,4 ГБ RAM	
Parquet + DuckDB	ХРАНЕНИЕ И АГРЕГАЦИИ
файл в 6,2 раза меньше • запрос 11,6 мс	
Spark	ИЗБЫТОЧЕН
данные помещаются на одну машину, обработка разовая	

От данных к проверяемой точке отсчёта

На полном снимке из 2 032 070 записей проверены типы, полнота, уникальность, диапазоны, согласованность, метка, репрезентативность и утечка.

Для модели сформировано 357 763 инспекций с однозначным FAILED/PASSED. Семь графиков объясняют структуру данных и ограничения анализа.

На временном тесте AP логистической модели — 0,928 против 0,794 у Dummy. Но приоритет получает 97,2 % проверок: практическая полезность требует локальных данных и подтверждённого лимита внимания.

Отчёт

14 СТРАНИЦ

Постановка, качество, EDA, baseline, план и риски

Notebook

ВЫПОЛНЕН

Все ячейки исполнены; результаты воспроизводимы

Данные

СНИМОК В GIT

Компактные таблицы + дата, источник и SHA-256

Проект

САМОСТОЯТЕЛЬНЫЙ

Аналитика курсового проекта; без привязки к диплому